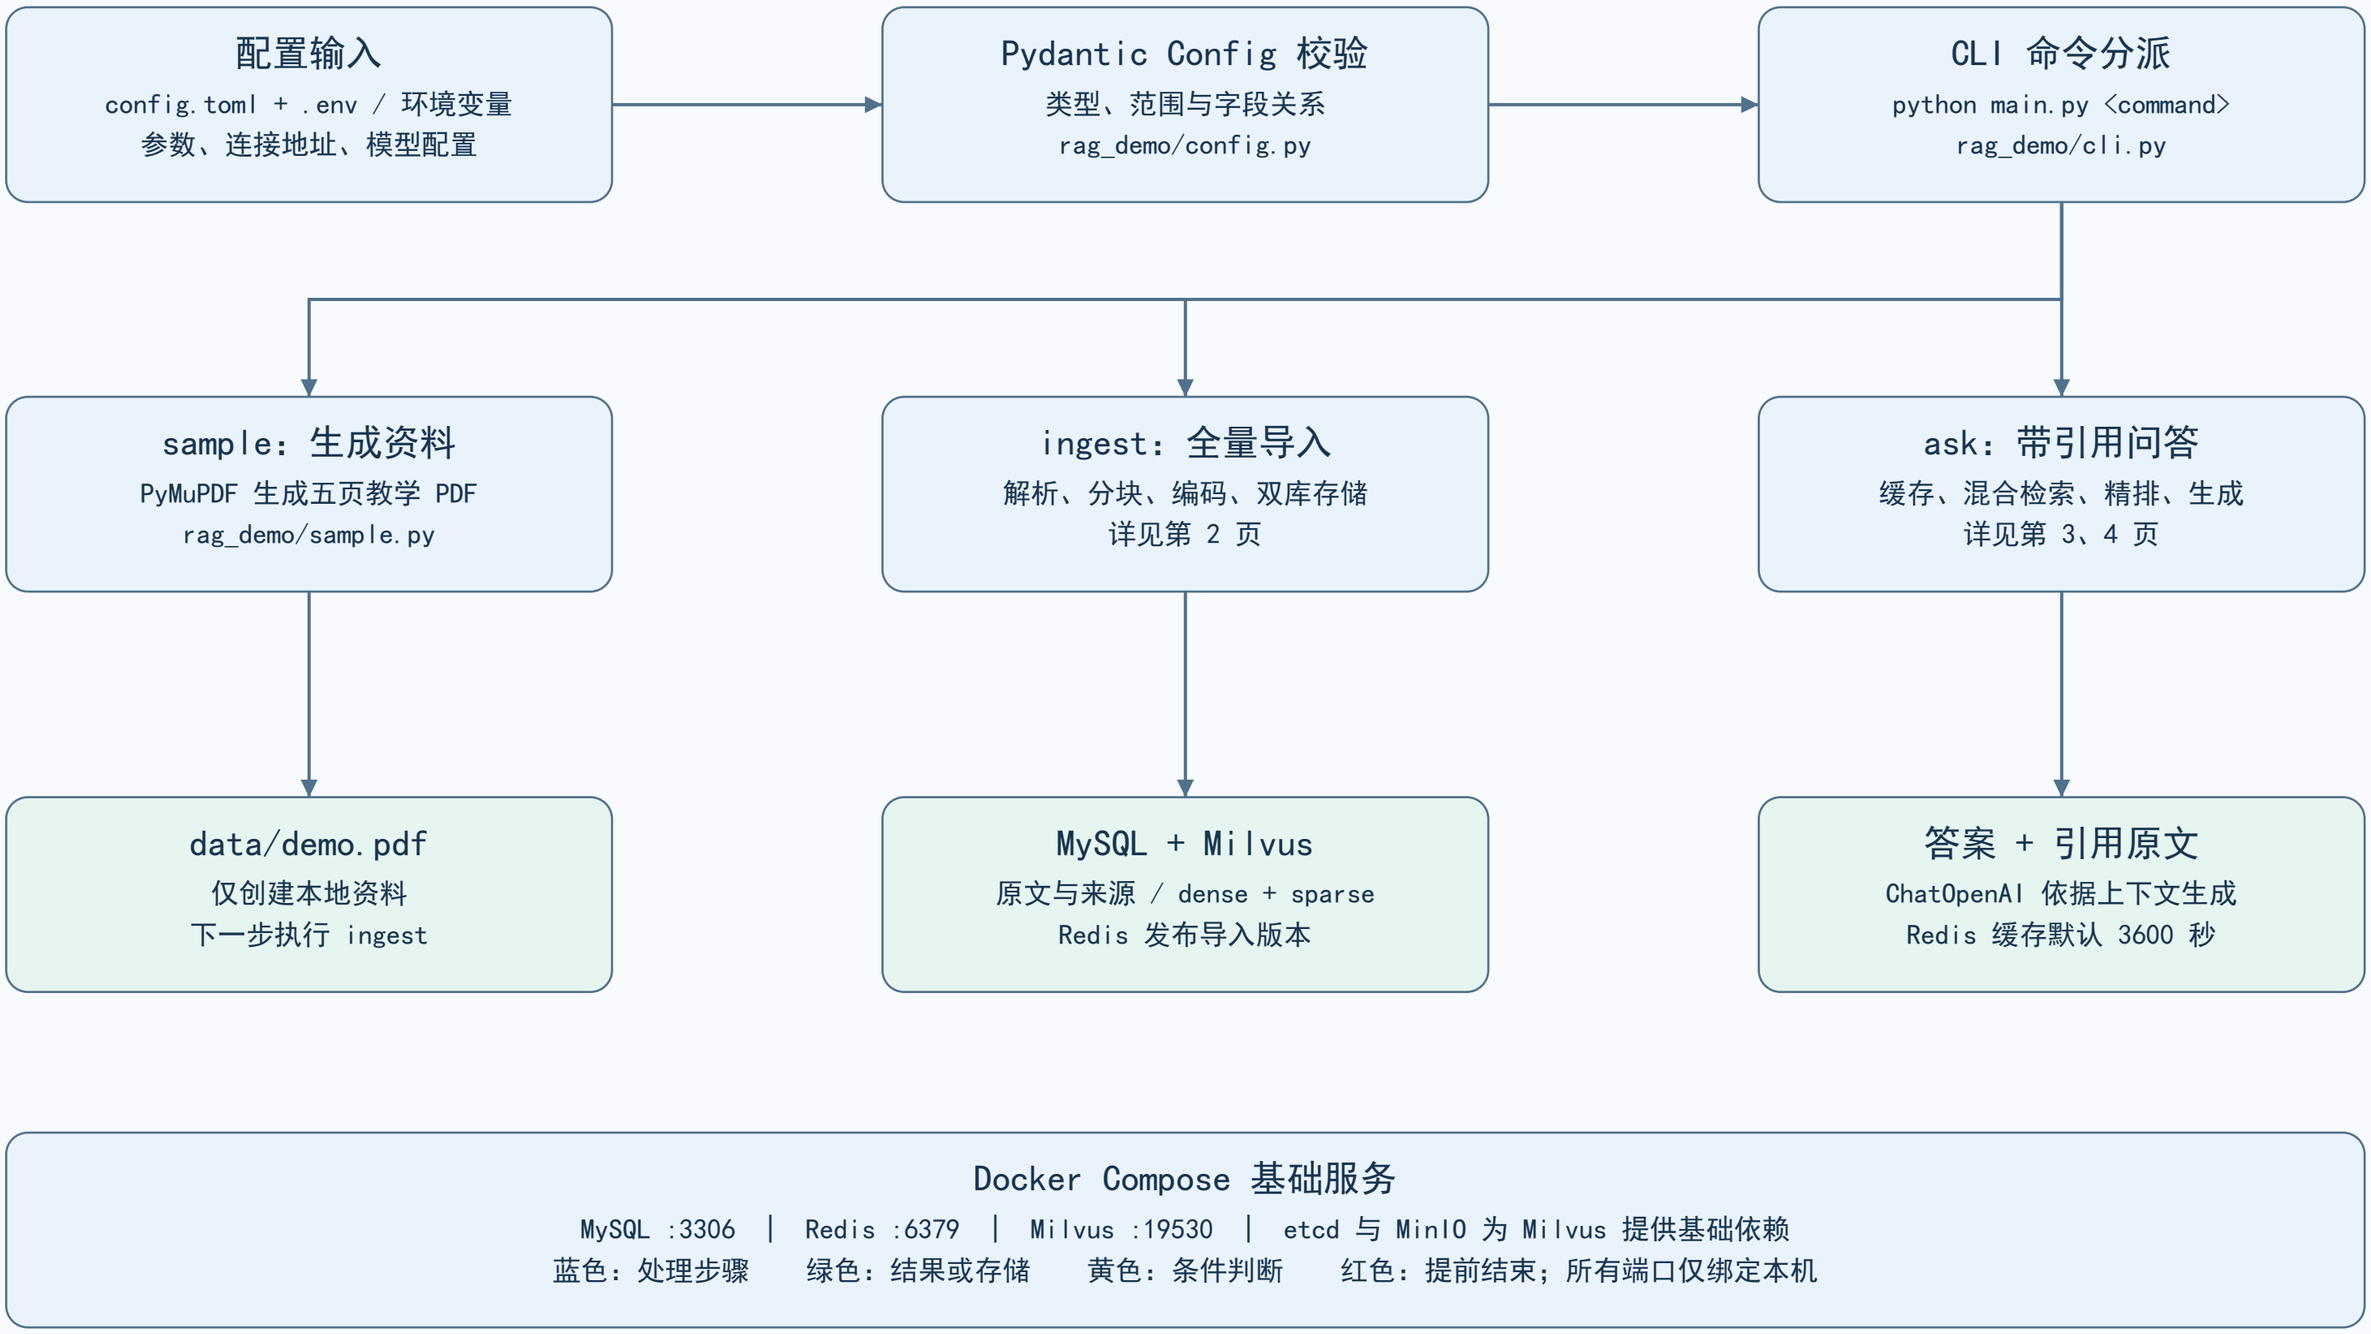
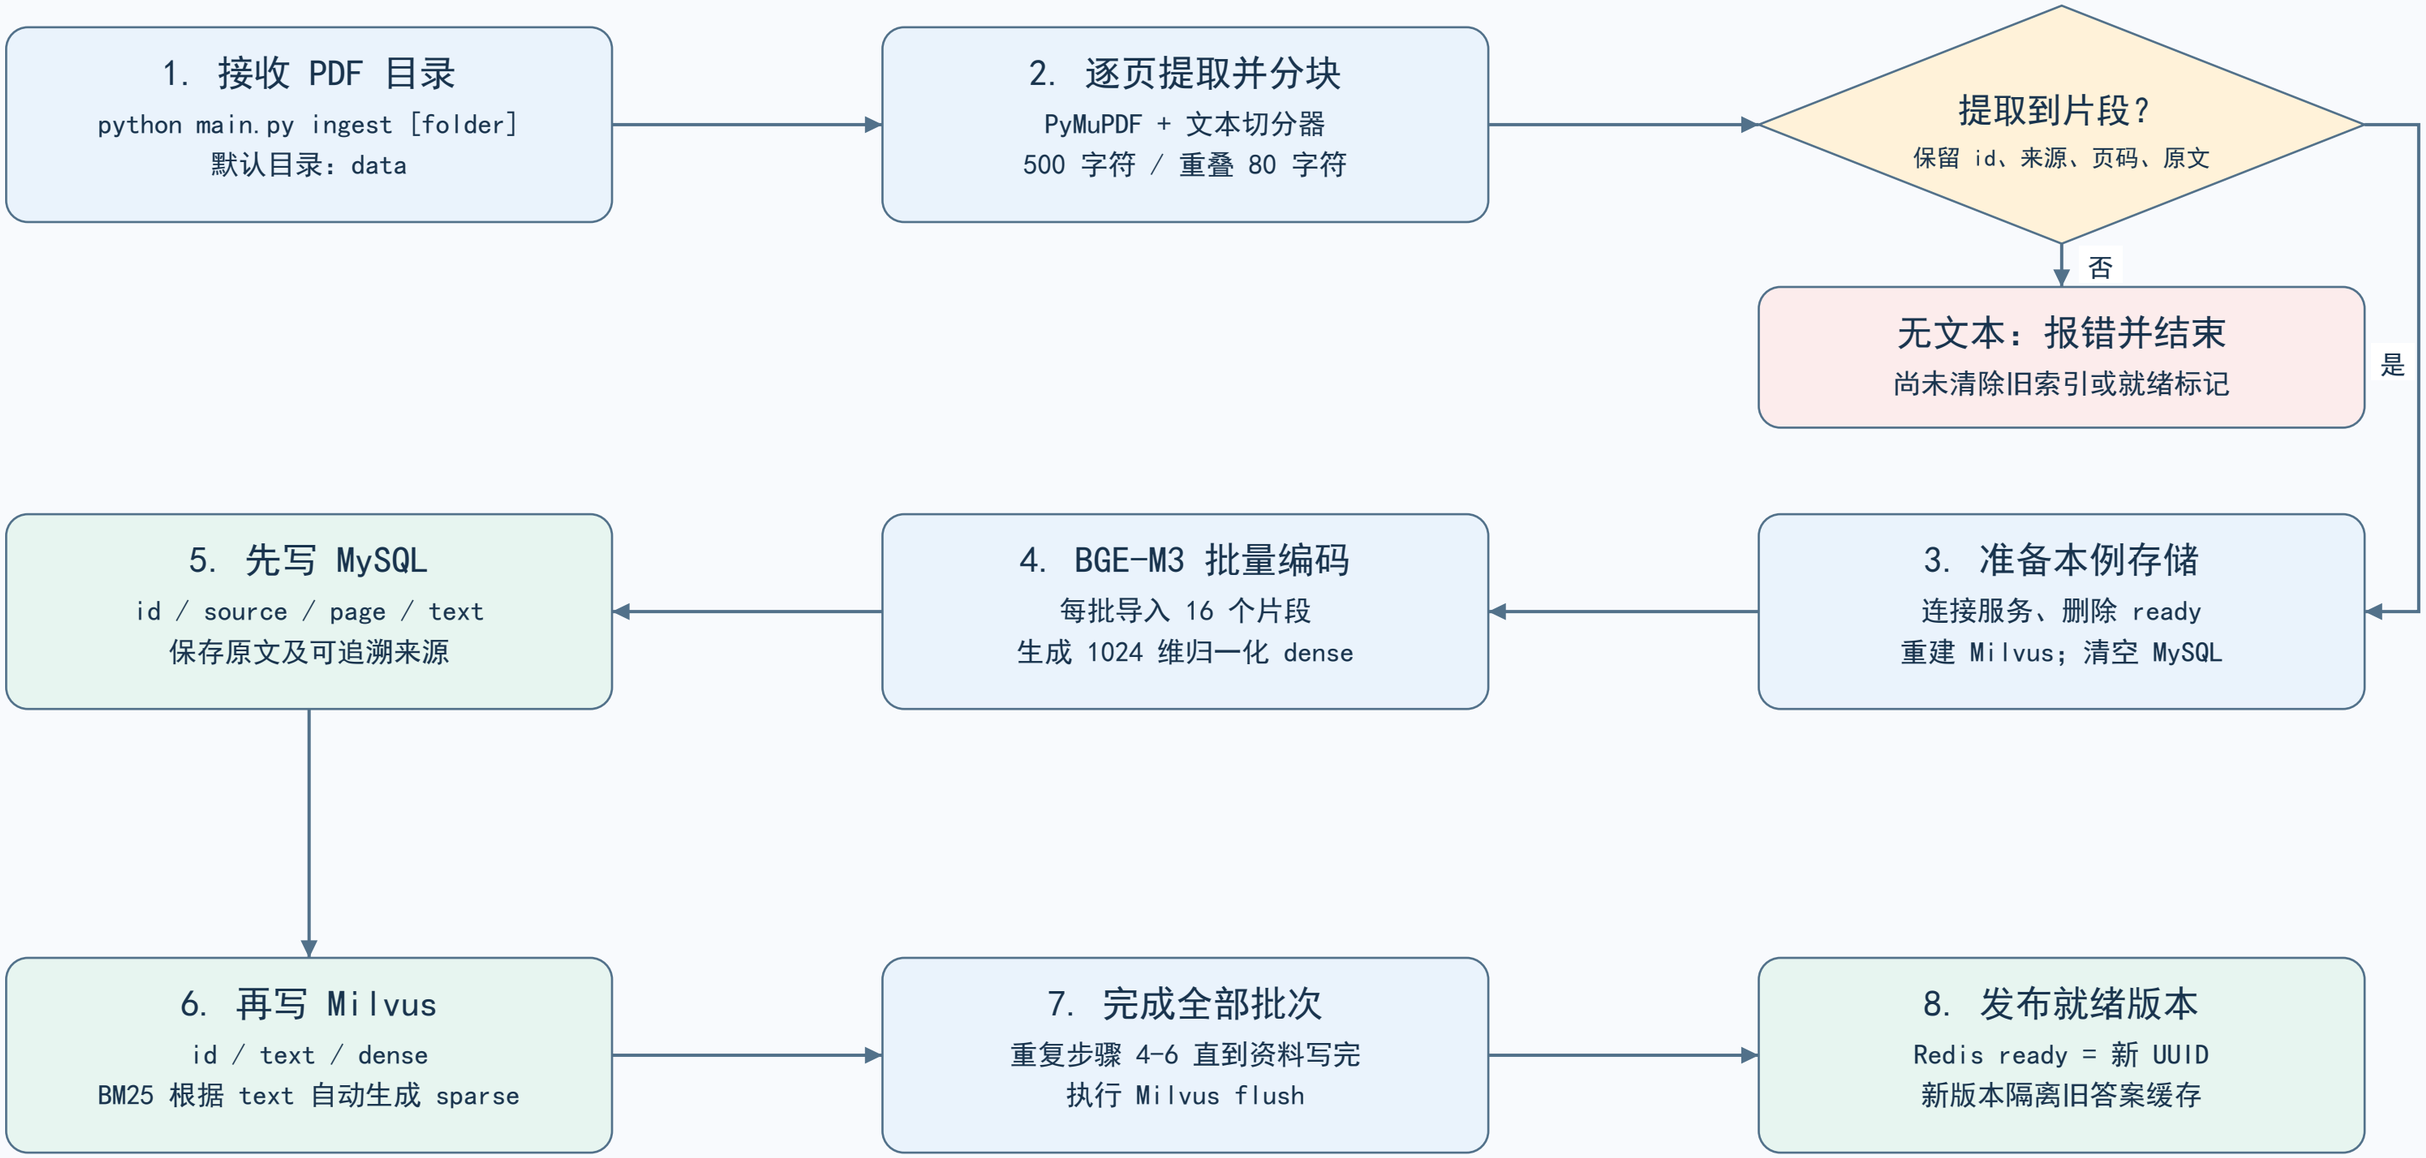
# 项目总览：配置、命令与基础服务

先校验配置，再选择演示命令；数据导入与用户问答是两条独立流程。



# 资料导入：PDF 如何成为可检索的知识库

按箭头从上排向右、中排向左、下排向右阅读；ingest 会替换本例已有数据。

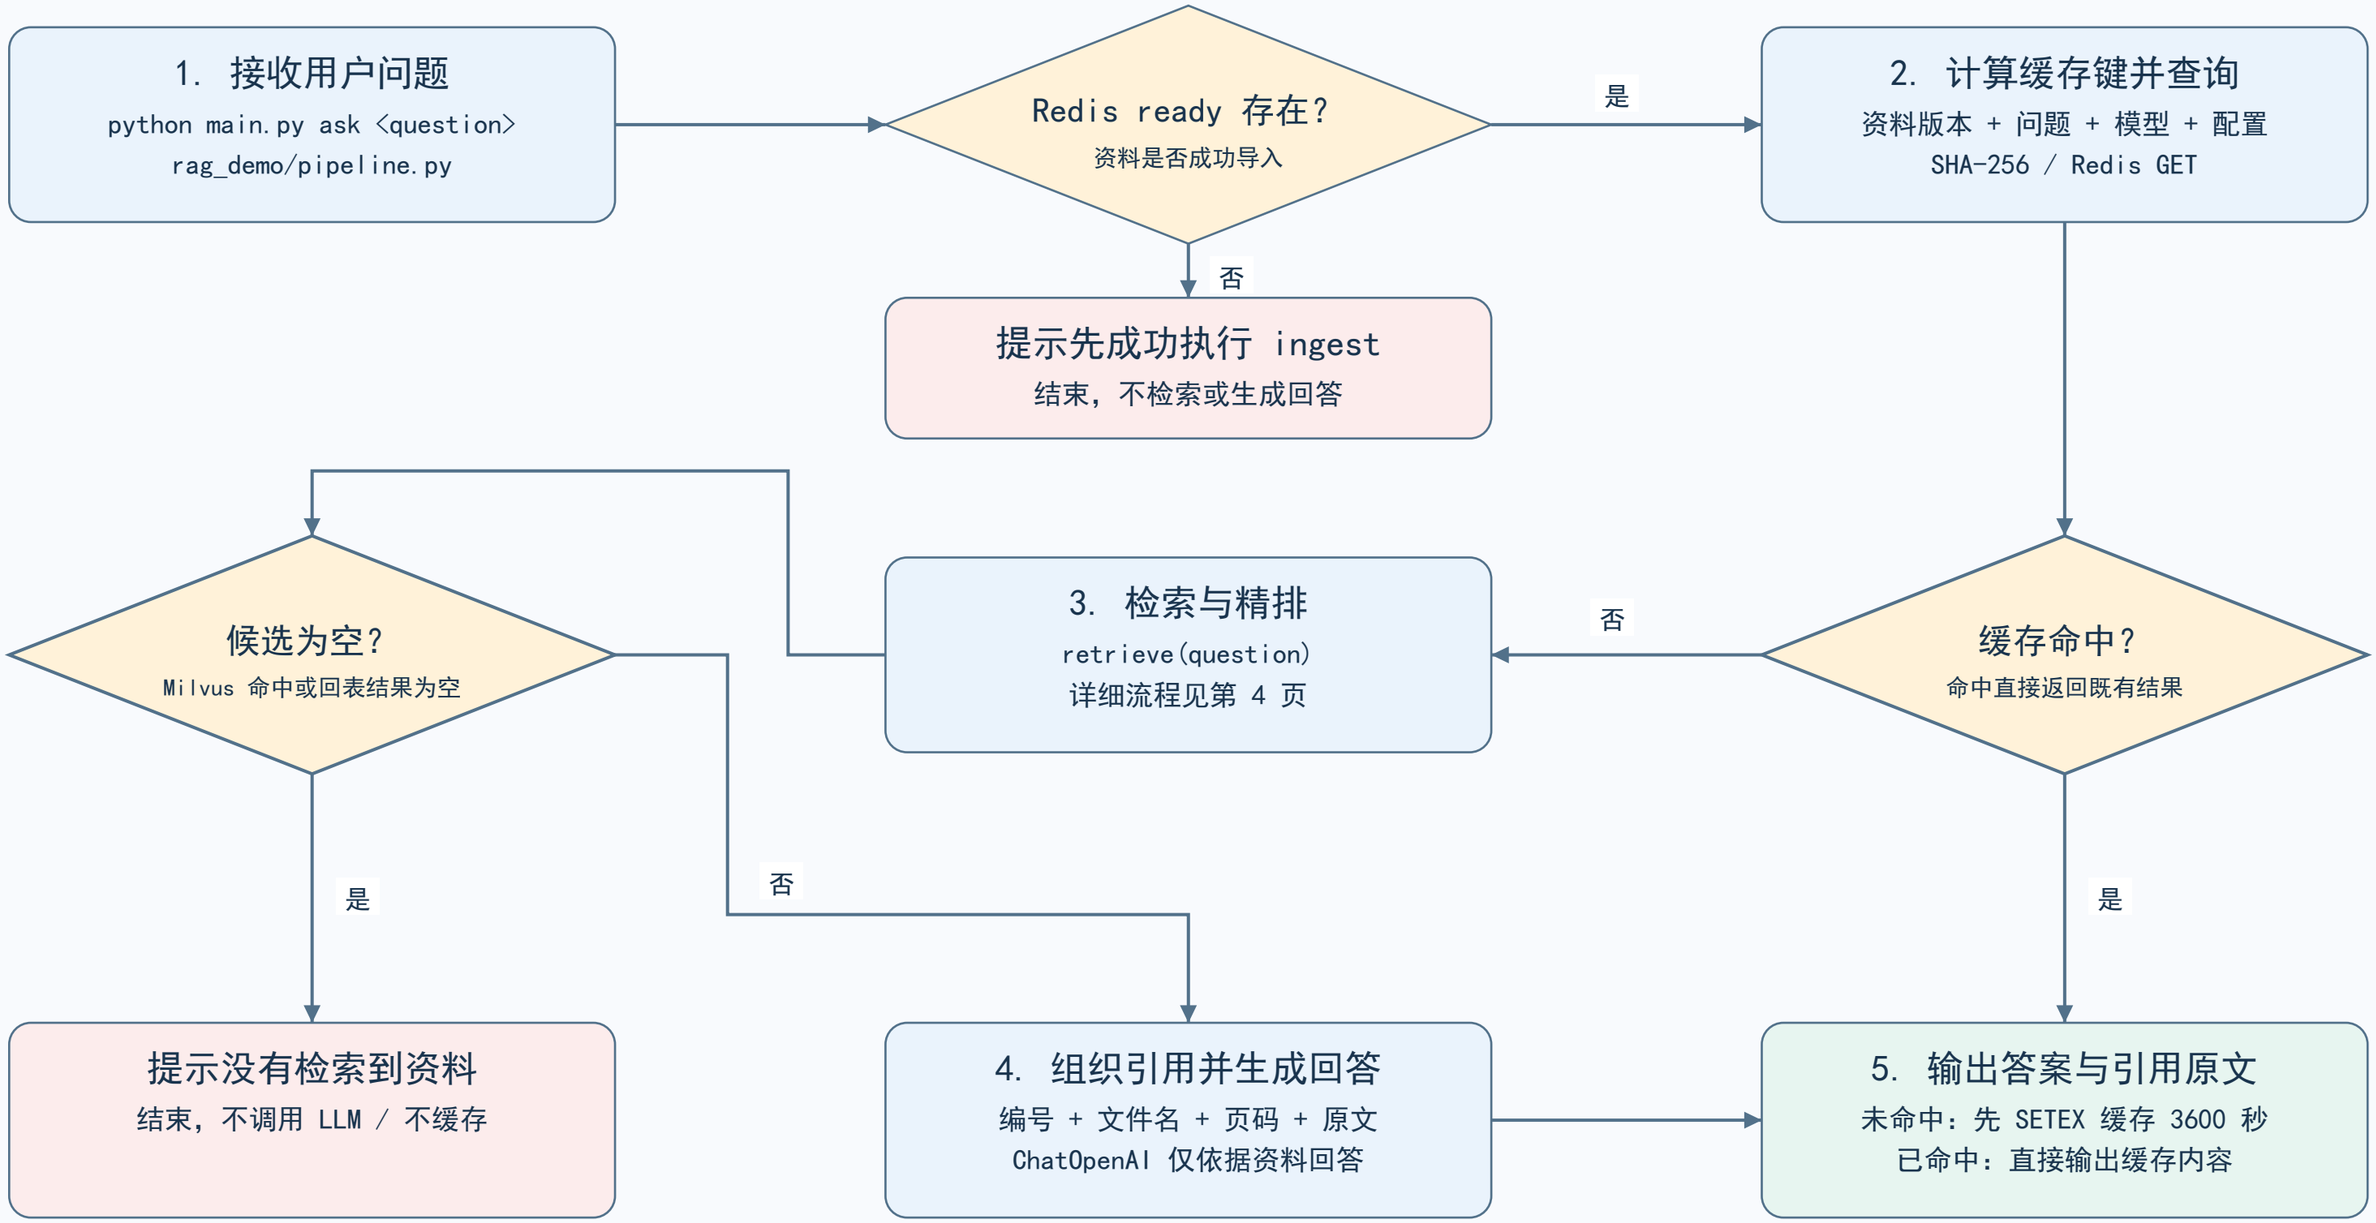



**教学要点：两库使用同一片段 ID；BM25 sparse 由 Milvus 生成，BGE-M3 仅提供 dense。**

失败处理：删除 ready 后若导入失败，不发布新版本；修复后重新导入。两库写入没有跨库事务。

# 用户问答：先检查版本与缓存，再执行 RAG

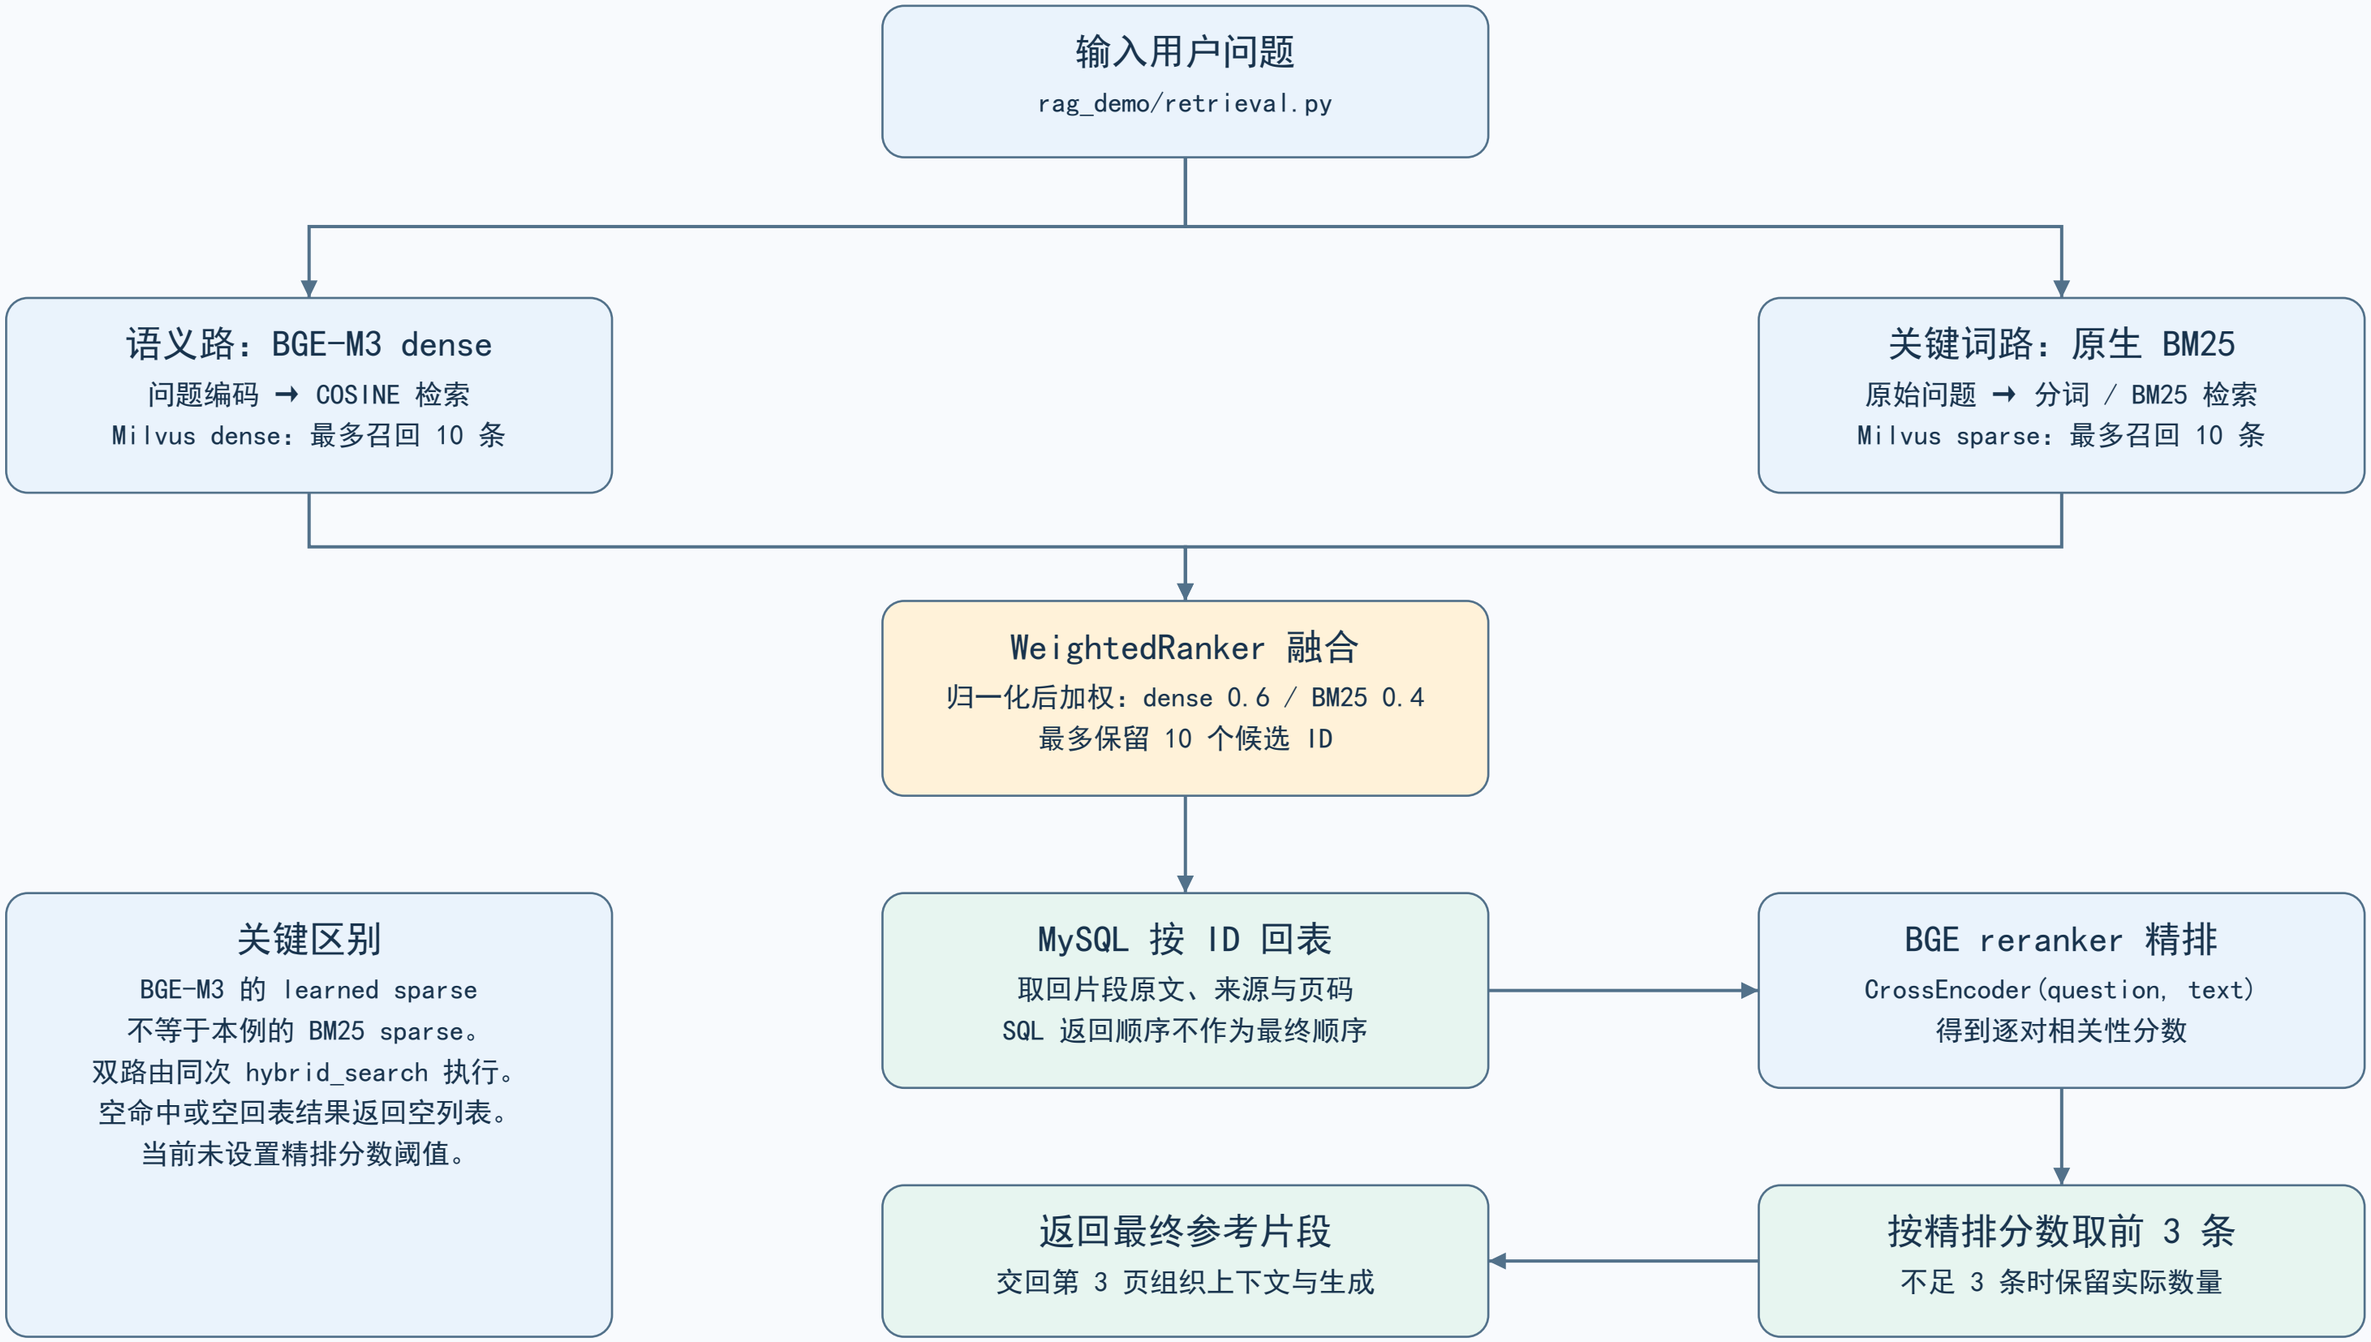
缓存命中绕过模型推理；没有可用资料时提前结束。




缓存键随资料版本与参数变化；模型调用或 Redis 操作异常向外抛出，当前没有自动降级流程。

# 检索细节：双路召回、加权融合与模型精排

WeightedRanker 融合检索分数；BGE reranker 重新阅读问题与原文，两者职责不同。




对应项目当前代码与默认配置；详细步骤见 docs/项目文字流程.md